

Raport z listy 1

Modele regresji i ich zastosowania

Ksawery Józefowski, album 277513

2026-03-11

Spis treści

1	Wstęp	2
2	Zadanie 1	2
3	Zadanie 2	3
4	Zadanie 3	4
5	Zadanie 4	4
6	Zadanie 5	5
7	Zadanie 6	6
8	Zadanie 7	6
9	Zadanie 8	7
10	Zadanie 9	10
11	Zadanie 10	10
11.1	Podpunkt (a)	10
11.2	Podpunkt (b)	11
11.3	Podpunkt (c)	11
11.4	Podpunkt (d)	12

1 Wstęp

Wczytujemy dane z pliku *lab 1 i 2.xlsx*.

```
library(readxl)
dane <- read_excel("C:/Users/ksawe/Desktop/MREG/lab 1 i 2.xlsx")
x <- dane$x
y <- dane$y
```

2 Zadanie 1

Wykorzystamy funkcję *wskazniki.statystyczne()*.

```
wskazniki.statystyczne <- function(x){
  wskazniki <- matrix(c(mean(x), var(x),
                        sd(x), median(x),
                        quantile(x, 0.25), quantile(x, 0.75),
                        min(x), max(x))
                    , nrow=8, ncol=1)

  rownames(wskazniki)<-c('średnia', "wariancja", "odchylenie standardowe",
                        "mediana", "pierwszy kwartył", "trzeci kwartył",
                        "minimum","maksimum")
  return(wskazniki)
}
```

Wyznaczamy szukane wskaźniki statystyczne dla zmiennych x oraz y .

```
x.stat <- wskazniki.statystyczne(x)
y.stat <- wskazniki.statystyczne(y)
```

Wyniki zebrano w tabeli 1.

	zmienna x	zmienna y
średnia	4.89	2040.64
wariancja	8.37	75.98
odchylenie standardowe	2.89	8.72
mediana	4.88	2040.88
pierwszy kwartył	2.32	2032.65
trzeci kwartył	7.51	2048.06
minimum	0.02	2024.69
maksimum	9.98	2056.66

Tabela 1: Wskaźniki statystyczne dla zmiennych x i y

Wnioski: Wskaźniki dla zmiennej y są wyraźnie większe niż dla zmiennej x . W obu przypadkach

wartości średniej i mediany są do siebie bardzo zbliżone, co wskazuje, że rozkłady tych zmiennych są w przybliżeniu symetryczne.

3 Zadanie 2


Próbkowy współczynnik korelacji Pearsona wyraża się wzorem

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}}$$

i jest zaimplementowany w funkcji `cor()`. Próbkowa wartość współczynnika korelacji Pearsona wynosi zatem 0.9945777.

Wykres rozrzutu zmiennych x, y jest przedstawiony na rysunku 1

```
plot(x, y,  
     main = "Wykres rozrzutu dla zmiennych x oraz y",  
     xlab = "x",  
     ylab = "y")
```



Rysunek 1: Wykres rozrzutu dla zmiennych x oraz y

Wnioski: Można zastosować model regresji liniowej, ponieważ wykres rozrzutu wskazuje na istnienie liniowej zależności między zmiennymi, a współczynnik korelacji Pearsona przyjmuje wartość bliską 1, co świadczy o silnej zależności między nimi.

4 Zadanie 3

Estymatory MNK (metody najmniejszych kwadratów, ang. LSE=Least Squares Errors) parametrów β_0 oraz β_1 są dane wzorami

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Wartości estymowanych współczynników możemy wyznaczyć przy użyciu funkcji *estymatory()*.

```
estymatory<-function(x,y){  
  beta1 <- sum((x - mean(x)) * (y - mean(y)))/sum((x-mean(x))^2)  
  beta0 <- mean(y) - beta1 * mean(x)  
  return(c(beta0, beta1))  
}
```

```
beta0 <- estymatory(x,y)[1]  
beta1 <- estymatory(x,y)[2]
```

Otrzymujemy oszacowania $\hat{\beta}_0 = 2025.9754064$ oraz $\hat{\beta}_1 = 2.9966636$.

5 Zadanie 4

Estymator σ^2 wyraża się wzorem

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

gdzie $\hat{y}_i$ oznacza prognozowaną przez model wartość zmiennej objaśnianej y_i , odpowiadającą wartości x_i , zmiennej objaśniającej x . Zatem

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 \cdot x_i.$$

Do wyznaczenia estymatora parametru σ^2 użyjemy odpowiednio funkcji *prognoza()* oraz *sigma2()*.

```
prognoza <- function(x, beta0, beta1){  
  y.est <- beta0 + beta1 * x  
  return(y.est)  
}  
  
sigma2 <- function(y,y.est){  
  n <- length(y)  
  sigma2.est <- (1/(n-2)) * sum((y - y.est)^2)  
  return(sigma2.est)  
}
```

```
y.est <- prognoza(x, beta0, beta1)
sigma2.est <- sigma2(y, y.est)
```

Otrzymujemy zatem, że $\hat{\sigma}^2 = 0.8258558$.

6 Zadanie 5

Na poziomie istotności $\alpha = 0.05$ weryfikujemy następującą hipotezę:

$$H_0 : \beta_1 = 0, \quad H_1 : \beta_1 \neq 0$$

W tym celu definiujemy statystykę $SE_{\beta_1}^2$ wzorem

$$SE_{\beta_1}^2 = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Jeśli hipoteza H_0 jest prawdziwa, to statystyka testowa ma postać

$$T = \frac{\hat{\beta}_1}{SE_{\beta_1}}$$

a jej rozkład to rozkład t-Studenta z $n - 2$ stopniami swobody tj. t_{n-2} . Skoro test odrzuca hipotezę zerową H_0 , gdy $|T| \geq t_{\alpha/2, n-2}$, to p-value (p-wartość) wyznaczamy ze wzoru

$$\text{p-value} = 2\mathbb{P}(|T| \geq |T_{obs}|) = 2(1 - F_{n-2}(|T_{obs}|))$$

gdzie $F_{n-2}(T_{obs})$ jest dystrybuantą rozkładu t_{n-2} dla zaobserwonej wartości T_{obs} statystyki T .

Do weryfikacji rozważanej hipotezy wykorzystamy funkcję *test.istotnosci()*.

```
test.istotnosci<-function(sigma2.est, x, beta1, alpha){
  SE2.beta1 <-sigma2.est / sum((x-mean(x))^2)
  T.stat <- beta1 / sqrt(SE2.beta1)
  t <- qt(1-alpha/2, length(x)-2)
  p.value <- 2*pt(abs(T.stat), length(x)-2, lower.tail = FALSE)

  y <- matrix(c(T.stat, t, p.value), ncol=3, nrow=1)
  colnames(y)<-c("Statystyka testowa","Kwantyl rzędu 1-alpha/2","p-value")
  return(y)
}
```

Tutaj $p - value$ wynosi $3.8792988 \times 10^{-198}$

Wnioski: Ponieważ wartość p-value jest mniejsza niż 0.05, odrzucamy hipotezę zerową H_0 . Oznacza to, że współczynnik kierunkowy jest statystycznie istotny, a więc zmienna objaśniana ma istotny wpływ na zmienną objaśnianą. W konsekwencji model regresji liniowej można uznać za istotny statystycznie.

Dokładne wyniki przeprowadzonego testu istotności współczynnika β_1 są podane w tabeli 2.

Statystyka testowa	Kwantyl rzędu 1-alpha/2	p-value
134.57	1.97	0.00

Tabela 2: Wyniki testu istotności współczynników modelu regresji

7 Zadanie 6

Do wyznaczenia realizacji przedziału ufności $[T_L(X), T_U(X)]$ na poziomie ufności $1 - \alpha$ dla parametru β_1 , przy założeniu, że $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ *i.i.d* o rozkładzie $\mathcal{N}(0, \sigma^2)$ wykorzystamy wzory

$$T_L(X) = \hat{\beta}_1 - t_{\alpha/2, n-2} \cdot SE_{\beta_1}, \quad T_U(X) = \hat{\beta}_1 + t_{\alpha/2, n-2} \cdot SE_{\beta_1}$$

i zaimplementujemy je w funkcji `przedzial.ufnosci.beta()`.

```
przedzial.ufnosci.beta <- function(sigma2.est,x,beta1,alpha){
  SE2.beta1 <-sigma2.est / sum((x-mean(x))^2)
  t <- qt(1-alpha/2, length(x)-2)
  t.lower <- beta1 - t * sqrt(SE2.beta1)
  t.upper <- beta1 + t * sqrt(SE2.beta1)
  y<-matrix(c(t.lower,t.upper),ncol=2,nrow=1)
  colnames(y)<-c("T-lower", "T-upper")
  return(y)
}

t.beta1 <- przedzial.ufnosci.beta(sigma2.est,x,beta1,0.01)
```

Realizacja przedziału ufności parametru β_1 na poziomie ufności $1 - \alpha = 0.99$ wynosi [2.9387465, 3.0545808]

8 Zadanie 7

Do wyznaczenia realizacji przedziału ufności $[T_L(X), T_U(X)]$ na poziomie ufności $1 - \alpha$ dla wartości $Y(x_0)$ prognozowanej przez model, przy założeniu, że $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ *i.i.d* o rozkładzie $\mathcal{N}(0, \sigma^2)$, wykorzystamy wzory

$$T_L(X) = Y(\hat{x}_0) - t_{\alpha/2, n-2} \cdot SE_{Y(\hat{x}_0)-Y(x_0)}, \quad T_U(X) = Y(\hat{x}_0) + t_{\alpha/2, n-2} \cdot SE_{Y(\hat{x}_0)-Y(x_0)},$$

gdzie

$$Y(\hat{x}_0) = \hat{\beta}_0 + \hat{\beta}_1 \cdot x_0$$

oraz

$$SE_{Y(\hat{x}_0)-Y(x_0)}^2 = \hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right).$$

i zaimplementujemy je w funkcji *przedział.ufności.prognoza()*, przy czym przyjmujemy, że $x_0 = 1$ a poziom ufności to $1 - \alpha = 0.99$.

```
przedział.ufności.prognoza<-function(sigma2.est, x, alpha, x_0, y_0){
  SE2.y <- sigma2.est * (1 + 1/length(x) + (x_0 - mean(x))^2 / (sum((x - mean(x))^2)))
  t <- qt(1-alpha/2, length(x)-2)
  y.pred <- prognoza(x_0, beta0, beta1)

  t.lower <- y.pred - t * sqrt(SE2.y)
  t.upper <- y.pred + t * sqrt(SE2.y)

  y <- matrix(c(t.lower,t.upper),ncol=2,nrow=1)
  colnames(y)<-c("T-lower","T-upper")
  return(y)
}
```

```
x_0 <- 1
y_0 <- prognoza(x_0, beta0, beta1)
t.prognoza <- przedział.ufności.prognoza(sigma2.est, x, 0.01, x_0, y_0)
```


Realizacja przedziału ufności dla wartości prognozowanej $Y(\hat{x}_0) = 2028.97207$ na poziomie ufności $1 - \alpha = 0.99$ wynosi [2026.5918669, 2031.3522731]

9 Zadanie 8

Wyznamy rezydua dla naszego modelu w oparciu o wartości zmiennych x i y za pomocą funkcji *rezydum()*.


```
rezydum<-function(y,y_0){
  y - y_0
}
```

Histogram rezydów jest przedstawiony na rysunku 2.




Rysunek 2: Histogram rezyduów

Wykres kwantylowy rezyduów jest przedstawiony na rysunku 2.




Rysunek 3: Wykres kwantylowy rezyduów

Wykres rozrzutu rezyduów względem estymowanych wartości jest przedstawiony na rysunku 4.



Rysunek 4: Wykres rozrzutu rezyduów względem prognoz

Wykres rozrzutu rezyduów względem wartości zmiennej x jest przedstawiony na rysunku 5.



Rysunek 5: Wykres rozrzutu rezyduów względem wartości zmiennej x

Wnioski: Histogram rezyduów wskazuje, że ich rozkład jest zbliżony do normalnego. Potwierdza to również wykres kwantyl–kwantyl, choć widoczne są pojedyncze obserwacje odstające

na krańcach rozkładu. Wykres rozrzutu rezyduów względem wartości prognozowanych nie wskazuje na istotną zależność ani wyraźny wzorec. Również wykres rozrzutu rezyduów względem wartości zmiennej x nie wykazuje istotnej korelacji ani systematycznej struktury punktów.

10 Zadanie 9

Modyfikujemy ostatnią wartość zmiennej y i wyznaczamy nowe estymatory parametrów β_0 oraz β_1 .

```
y.new <- y
y.new[length(y.new)] <- 10 * y.new[length(y.new)]
beta.new <- estymatory(x, y.new)
beta0.new <- beta.new[1]
beta1.new <- beta.new[2]
```

```
beta0.new
```

```
## [1] 2171.825
```

```
beta1.new
```

```
## [1] -8.06216
```

Wnioski: Modyfikacja ostatniej wartości zmiennej y znacząco wpływa (jest wpływowa) na wartości estymatorów $\hat{\beta}_0$ oraz $\hat{\beta}_1$. W przypadku $\hat{\beta}_1$ współczynnik kierunkowy zmienia znak z dodatniego na ujemny. Świadczy to o dużej wrażliwości modelu na tę obserwację. Można ją uznać za obserwację odstającą, ponieważ wyraźnie odbiega od pozostałych danych.

11 Zadanie 10

Generujemy próby $(x_1, x_2, \dots, x_n)$ oraz $(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)$.

```
n <- 200
beta.0 <- 1
beta.1 <- 2
sigma <- 0.1
x.10 <- runif(n, -2, 2)
```

11.1 Podpunkt (a)


Tworzymy funkcję *generuj_y* do generowania próby $(y_1, y_2, \dots, y_n)$.

```
generuj_y <- function(beta.0, beta.1, x.10, sigma){
  eps <- rnorm(n, mean=0, sd=sigma)
  y <- beta.0 + beta.1 * x.10 + eps
  return(y)
```

```
}  
  
y.10 <- generuj_y(beta.0, beta.1, x.10, sigma)
```

11.2 Podpunkt (b)

Wykres rozproszenia jest pokazany na rysunku 6



Rysunek 6: Wykres rozrzutu próby

Wnioski: Chmura punktów na wykresie rozrzutu dla nowej próby ma charakter liniowy, co wskazuje na występowanie korelacji między zmiennymi. Wynika to ze sposobu generowania danych.

11.3 Podpunkt (c)

Wyznaczamy szukane estymatory.

```
beta.10 <- estymatory(x.10, y.10)  
beta.0.est <- beta.10[1]  
beta.1.est <- beta.10[2]
```

```
# beta.0.est
# beta.1.est
```

Wyniki są podane w tabeli 3.

	Wartość dokładna	Oszacowanie
beta.0	1.0000	0.9985
beta.1	2.0000	2.0067

Tabela 3: Współczynniki modelu regresji z zadania 10.

Wnioski: Nowe estymatory są bardzo zbliżone do wyjściowych estymatorów. Błędy są bardzo małe i wynikają z dodania szumu gaussowskiego.

11.4 Podpunkt (d)

Tworzymy funkcję $R2()$ do wyznaczania współczynnika determinacji.

```
R2 <- function(y, y.est){
  sum((y.est - mean(y))^2)/sum((y - mean(y))^2)
}
```

Powtarzamy obliczenia dla $\sigma = 0.5$ oraz $\sigma = 1$.

```
# Sigma = 0.1
sigma <- 0.1
y.0.1 <- generuj_y(beta.0, beta.1, x.10, sigma)
beta.0.0.1 <- estymatory(x.10, y.0.1)[1]
beta.1.0.1 <- estymatory(x.10, y.0.1)[2]
y.est.0.1 <- prognoza(x.10, beta.0.0.1, beta.1.0.1)
R2.s.0.1 <- R2(y.0.1, y.est.0.1)

# Sigma = 0.5
sigma <- 0.5
y.0.5 <- generuj_y(beta.0, beta.1, x.10, sigma)
beta.0.0.5 <- estymatory(x.10, y.0.5)[1]
beta.1.0.5 <- estymatory(x.10, y.0.5)[2]
y.est.0.5 <- prognoza(x.10, beta.0.0.5, beta.1.0.5)
R2.s.0.5 <- R2(y.0.5, y.est.0.5)

# Sigma = 1
sigma <- 1
y.1.0 <- generuj_y(beta.0, beta.1, x.10, sigma)
beta.0.1.0 <- estymatory(x.10, y.1.0)[1]
beta.1.1.0 <- estymatory(x.10, y.1.0)[2]
```

```
y.est.1.0 <- prognoza(x.10, beta.0.1.0, beta.1.1.0)
R2.s.1.0 <- R2(y.1.0, y.est.1.0)
```

Wyniki podane są w tabeli 4.

	sigma=0.1	sigma=0.5	sigma=1
1	0.9984	0.9564	0.8799

Tabela 4: Współczynnik determinacji dla różnych sigma

```
c(abs(1-beta.0.0.1),
  abs(1-beta.0.0.5),
  abs(1-beta.0.1.0))
```

```
## [1] 0.0002457761 0.0580231272 0.0843262335
```

```
c(abs(2-beta.1.0.1),
  abs(2-beta.1.0.5),
  abs(2-beta.1.1.0))
```

```
## [1] 0.001899413 0.019330805 0.179971966
```

Wnioski: Wraz ze wzrostem σ , maleje współczynnik dopasowania oraz estymatory β są coraz mniej dokładne (błąd rośnie). Jest to zgodne z oczekiwaniami, ponieważ wraz ze wzrostem wariancji rośnie rozproszenie danych, przez co model ma trudność z dokładnym dopasowaniem zależności.