

Lista lab 3

Modele regresji i ich zastosowania

Ksawery Józefowski, album 277513

2026-03-18

Spis treści

1	Wstęp	2
2	Zadanie 1	2
3	Zadanie 2	5
4	Zadanie 3	5
5	Zadanie 4	6
6	Zadanie 5	9
7	Zadanie 6	9
8	Zadanie 7	10

1 Wstęp

Wczytujemy dane z pliku *lab 3 (2026).xlsx*.

```
library(kableExtra)
library(readxl)
dane <- read_excel("C:/Users/ksawe/Desktop/MREG/lab 3 (2026).xlsx")
x <- dane$x
y <- dane$y
```

2 Zadanie 1

```
x_bar <- mean(x)
y_bar <- mean(y)

beta1 <- sum((x - x_bar) * (y - y_bar)) / sum((x - x_bar)^2)
beta0 <- y_bar - beta1 * x_bar


y_hat <- beta0 + beta1 * x
R2 <- sum((y_hat - y_bar)^2) / sum((y - y_bar)^2)

e <- y - y_hat

# Histogram reszt
hist(e,
      main = "Histogram reszt",
      xlab = "Reszty")
```




```
# Wykres QQ
qqnorm(e)
qqline(e, col = "red")
```



```
# Reszty vs dopasowane
plot(y_hat, e,
     main = "Reszty vs dopasowane",
     xlab = "y_hat",
     ylab = "reszty")
```


```
abline(h = 0)
```

Reszty vs dopasowane



```
# Reszty vs x  
plot(x, e,  
      main = "Reszty vs x",  
      xlab = "x",  
      ylab = "reszty")  
abline(h = 0)
```

Reszty vs x




Wnioski: Model regresji liniowej słabo opisuje zależność między zmiennymi, ponieważ współczynnik determinacji wynosi około 0.8101715, a analiza reszt wskazuje jednak na obecność pojedynczych dużych odchyleń, co może sugerować występowanie obserwacji odstających. Wykresy zależności wskazują na występowanie zależności między resztami. Ogólnie model można uznać za poprawny, choć nie idealny.

3 Zadanie 2

Wykres rozrzutu zmiennych x, y jest przedstawiony na rysunku 1

```
plot(x, y,  
     main = "Wykres rozrzutu dla zmiennych x oraz y",  
     xlab = "x",  
     ylab = "y")  
lines(x, y_hat, col = "red", lwd = 2)
```

Wykres rozrzutu dla zmiennych x oraz y



Rysunek 1: Wykres rozrzutu dla zmiennych x oraz y

Wnioski: Wykres rozrzutu wskazuje na nieliniowość trendu, dopiero od około $x = 15$ można stwierdzić, że zachowuje on się liniowo. Ogólnie trend zachowuje się logarytmicznie.

4 Zadanie 3

```
x_tilde <- log(x)
```

Wnioski: Z histogramu dla reszt widać, że na początku występują duże ujemne błędy, a wykres rozrzutu wskazuje na szybki wzrost wartości danych na początku. Jak już wcześniej zauważyliśmy wskazuje to na nieliniowość trendu, a wręcz wygląda on logarytmicznie. Transformacja logarytmiczna idealnie będzie pasować do aktualnego zachowania trendu tym samym go liniaryzując go.

5 Zadanie 4


```
x_bar_t <- mean(x_tilde)
y_bar <- mean(y)

beta1_t <- sum((x_tilde - x_bar_t) * (y - y_bar)) / sum((x_tilde - x_bar_t)^2)
beta0_t <- y_bar - beta1_t * x_bar_t

y_hat_t <- beta0_t + beta1_t * x_tilde

R2_t <- sum((y_hat_t - y_bar)^2) / sum((y - y_bar)^2)
e_t <- y - y_hat_t
```


```
plot(x, y)
lines(x, y_hat_t, col = "red", lwd = 2)
```



```
# Histogram reszt
hist(e_t,
      main = "Histogram reszt",
      xlab = "Reszty")
```




```
# Wykres QQ
qqnorm(e_t)
qqline(e_t, col = "red")
```



```
# Reszty vs dopasowane
plot(y_hat_t, e_t,
     main = "Reszty vs dopasowane",
     xlab = "y_hat",
     ylab = "reszty")
```


```
abline(h = 0)
```

Reszty vs dopasowane



```
# Reszty vs x  
plot(x, e_t,  
      main = "Reszty vs x",  
      xlab = "x",  
      ylab = "reszty")  
abline(h = 0)
```

Reszty vs x



Wnioski: Model po transformacji logarytmicznej bardzo dobrze opisuje zależność między zmiennymi, ponieważ współczynnik determinacji wynosi około 0.9765857, a reszty wyglądają na losowe. Również wykres kwantylowy i histogram reszt wskazują na dobre dopasowanie do rozkładu normalnego.

6 Zadanie 5

Model liniowy bez transformacji osiąga współczynnik determinacji 0.8101715, co oznacza dobre dopasowanie, jednak analiza reszt wskazuje na pewną nieliniowość. Szczególnie dla małych wartości X występują duże odchylenia, więc ogólnie dopasowanie jest słabe.

Po zastosowaniu transformacji logarytmicznej zmiennej X wartość 0.9765857 wzrasta, a reszty mają bardziej losowy charakter i są lepiej rozproszone wokół zera. Również ich wykres kwantylowy jak i histogram bardziej przypominają rozkład normalny.

Finalnie model z transformacją lepiej opisuje zależność między zmiennymi.

7 Zadanie 6

```
tab <- data.frame(
  Nr = 1:length(y),
  Y_obserwowane = y,
  Y_hat_stary = y_hat,
  Y_hat_nowy = y_hat_t
)

kable(tab, digits = 3)
```

Nr	Y_obserwowane	Y_hat_stary	Y_hat_nowy
1	1.620	6.772	1.878
2	4.429	6.941	3.987
3	5.395	7.110	5.221
4	5.632	7.279	6.096
5	6.626	7.448	6.775
6	7.953	7.617	7.330
7	6.988	7.786	7.799
8	8.088	7.955	8.205
9	9.035	8.124	8.563
10	8.604	8.293	8.884
11	8.956	8.462	9.174
12	9.422	8.631	9.439
13	10.217	8.800	9.682
14	9.694	8.969	9.908

Nr	Y_obserwowane	Y_hat_stary	Y_hat_nowy
15	9.969	9.138	10.118
16	10.166	9.308	10.314
17	11.272	9.477	10.498
18	11.436	9.646	10.672
19	11.185	9.815	10.837
20	11.122	9.984	10.993
21	11.392	10.153	11.141
22	11.795	10.322	11.283
23	11.079	10.491	11.418
24	11.946	10.660	11.548
25	11.218	10.829	11.672
26	11.551	10.998	11.791
27	12.205	11.167	11.906
28	11.497	11.336	12.017
29	12.053	11.505	12.123
30	11.902	11.674	12.227
31	12.212	11.843	12.326
32	11.418	12.012	12.423
33	11.869	12.181	12.517
34	12.334	12.350	12.607
35	12.991	12.519	12.696
36	12.690	12.688	12.781
37	12.834	12.857	12.865
38	13.154	13.026	12.946
39	12.683	13.195	13.025
40	13.166	13.364	13.102
41	12.859	13.533	13.177
42	12.608	13.702	13.250
43	13.147	13.871	13.322
44	13.553	14.040	13.392
45	13.538	14.209	13.460
46	13.482	14.378	13.527
47	14.388	14.548	13.593
48	13.758	14.717	13.657
49	14.018	14.886	13.719
50	14.519	15.055	13.781

8 Zadanie 7

Transformacja zmiennej objaśniającej była opłacalna, ponieważ początkowe wartości prognozowane w nowym modelu są bliższe wartościom obserwowanym. Potwierdza to również wyższy współczynnik determinacji oraz lepsze własności reszt.