

Raport z listy 4

Modele regresji i ich zastosowania

Ksawery Józefowski, album 277513

2026-03-25

Spis treści

1	Wstęp	2
2	Zadanie 1	2
2.1	Podpunkt (a)	2
2.2	Podpunkt (b)	2
2.3	Podpunkt (c)	3
3	Zadanie 2	3
3.1	Podpunkt (a)	3
3.2	Podpunkt (b)	4
4	Zadanie 3	4
4.1	Podpunkt (a)	4
4.2	Podpunkt (b)	5
4.3	Podpunkt (c)	6
5	Zadanie 4	7
5.1	Podpunkt (a)	7
5.2	Podpunkt (b)	7
6	Zadanie 5	9
6.1	Podpunkt (a)	9
6.2	Podpunkt (c)	10
6.3	Podpunkt (b)	11
7	Zadanie 6	12
7.1	Podpunkt (a)	12
7.2	Podpunkt (b)	13
7.3	Podpunkt (c)	13


1 Wstęp

Wczytujemy dane z pliku *regresja wielokrotna 2026.xlsx*.

```
library(openxlsx)
library(kableExtra)
dane <- read.xlsx("C:/Users/ksawe/Desktop/MREG/lab4.xlsx")
dane.2 <- dane
```

2 Zadanie 1

```
pairs(dane.2, cex=0.5)
```



2.1 Podpunkt (a)

Potencjalne zmienne objaśniające, które mogą mieć liniowy wpływ na zmienną objaśnianą to na przykład X_6 , której wykres rozrzutu najbardziej przypomina trend liniowy, pozostałe które potencjalnie zachowują się liniowo to X_8, X_9, X_{10} .

2.2 Podpunkt (b)

Tak pojawia się problem współliniowości, głównie między parami $(X_2, X_8), (X_6, X_9), (X_2, X_{10}), (X_8, X_{10})$

2.3 Podpunkt (c)

Tak, na wykresach można zauważyć obserwacje, które znacznie odstają od występujących czarnych skupisk.

3 Zadanie 2

Próbkowy współczynnik korelacji Pearsona wyraża się wzorem

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}}$$

i jest zaimplementowany w funkcji `cor()`.

```
kable(cor(dane.2), digits=3)
```

	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	Y
X1	1.000	-	0.018	0.025	0.147	0.072	0.010	0.082	-	0.198	0.107
		0.026							0.032		
X2	-	1.000	0.064	-	-	0.061	-	0.946	-	0.969	0.568
		0.026		0.030	0.071		0.130		0.082		
X3	0.018	0.064	1.000	-	-	0.091	0.145	0.367	-	0.071	0.272
				0.094	0.013				0.108		
X4	0.025	-	-	1.000	0.072	0.013	0.090	-	0.194	-	0.184
		0.030	0.094					0.055		0.016	
X5	0.147	-	-	0.072	1.000	0.124	-	-	0.105	-	0.073
		0.071	0.013				0.058	0.056		0.024	
X6	0.072	0.061	0.091	0.013	0.124	1.000	-	0.091	-	0.071	0.805
							0.024		0.955		
X7	0.010	-	0.145	0.090	-	-	1.000	-	0.031	-	0.036
		0.130			0.058	0.024		0.073		0.119	
X8	0.082	0.946	0.367	-	-	0.091	-	1.000	-	0.942	0.622
				0.055	0.056		0.073		0.112		
X9	-	-	-	0.194	0.105	-	0.031	-	1.000	-	-
		0.032	0.082	0.108		0.955		0.112		0.078	0.741
X10	0.198	0.969	0.071	-	-	0.071	-	0.942	-	1.000	0.577
				0.016	0.024		0.119		0.078		
Y	0.107	0.568	0.272	0.184	0.073	0.805	0.036	0.622	-	0.577	1.000
									0.741		

3.1 Podpunkt (a)

Współczynnik korelacji potwierdza, że zmienna objaśniająca X_6 jest “najlepiej” liniowa względem Y , również zmienne X_8 i X_9 są w miarę liniowe względem Y

3.2 Podpunkt (b)

Tak pojawia się problem współliniowości, teraz potwierdzony przez korelacje między nimi, głównie dla par $(X2, X8)$, $(X6, X9)$, $(X2, X10)$, $(X8, X10)$

4 Zadanie 3

Konstruujemy model regresji liniowej opisujący zależność pomiędzy zmienną objaśnianą Y a zmiennymi objaśniającymi $X_1, X_2, \dots, X_{10}$.

W tym celu wyznaczymy estymator

$$\hat{\beta} = (\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_{10})$$

parametrów

$$\beta = (\beta_1, \beta_2, \dots, \beta_{10})$$

tego modelu regresji liniowej.

4.1 Podpunkt (a)

Posłużymy się metodą najmniejszych kwadratów. Wówczas mamy

$$\hat{\beta} = (\mathbb{X}^T \mathbb{X})^{-1} \mathbb{X}^T Y$$

Wzór ten jest zaimplementowany w funkcji *estymatory.beta()*.

```
estymatory.beta<-function(x,y){  
  wektor.1 <- rep(1, length(y))  
  x <- cbind(wektor.1, x)  
  beta <- solve(t(x) %*% x) %*% (t(x) %*% y)  
  
  return(beta)  
}
```

```
X <- as.matrix(dane[, -11])  
Y <- as.matrix(dane[, 11])  
  
beta <- estymatory.beta(X, Y)  
kable(beta, digits=3)
```

wektor.1	-0.366
X1	1.312
X2	2.482
X3	3.644
X4	4.413

X5	0.483
X6	5.103
X7	1.051
X8	0.837
X9	-0.439
X10	-0.154

4.2 Podpunkt (b)

Funkcja *prognoza()* implementuje wzór na predykcje:

$$\hat{Y} = \mathbb{X}\hat{\beta}.$$

```
prognoza<-function(x,beta){
  wektor.1 <- rep(1, length(x[,1]))
  x <- cbind(wektor.1, x)
  return(x %*% beta)
}
```

```
Y.hat <- prognoza(X, beta)
```

Do zweryfikowania hipotezy zerowej

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_{p-2} = \beta_{p-1} = 0,$$

przy alternatywie

$$H_1 : \beta_1 \neq 0 \vee \beta_2 \neq 0 \vee \dots \vee \beta_{p-2} \neq 0 \vee \beta_{p-1} \neq 0,$$

wykorzystamy statystykę testową F określoną następująco:

$$F = \frac{SSR}{SSE} \cdot \frac{n-p}{p-1},$$

gdzie

- n jest długością próby,
- p jest liczbą zmiennych objaśniających powiększoną o jeden (zmienną $X_0 = 1$),
- $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$,
- $SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$

Hipotezę H_0 odrzucamy, gdy p-value określona jako

$$p - value = \mathbb{P}_{H_0}(F \geq F_{obs}) = 1 - F_{p-1, n-p}(F_{obs})$$

spełnia

$$p - value \leq \alpha$$

dla ustalonego wcześniej poziomu istotności α , przy czym $F_{m_1, m_2}(t)$ jest dystrybuantą rozkładu F Snedecora, z m_1, m_2 stopniami swobody, ewaluowaną w punkcie t .

Opisany test został zaimplementowany w funkcji *test.F()*.

```
test.F<-function(x,y,y.hat){
  p <- length(x[1,]) +1
  n <- length(x[,1])
  y.mean <- mean(y)
  SSR <- sum((y.hat - y.mean)^2)
  SSE <- sum((y.hat - y)^2)
  F.stat <- (SSR / SSE) * ((n - p) / (p - 1))
  p.value <- 1 - pf(F.stat, df1 = p - 1, df2 = n - p)
  return(p.value)}

p.value <- test.F(X, Y, Y.hat)
```

Wartość p-value wynosi 0, więc odrzucamy hipotezę H_0 , co oznacza, że co najmniej jedna zmienna objaśniająca ma istotny wpływ na zmienną objaśnianą.

4.3 Podpunkt (c)

Wartości współczynnika determinacji obliczamy ze wzoru

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

zaimplementowanego w funkcji *współczynnik.determinacji()*.

```
współczynnik.determinacji<-function(y,y.est){
  y.mean <- mean(y)
  SSR <- sum((y.est - y.mean)^2)
  SST <- sum((y - y.mean)^2)
  return(SSR / SST)
}
```

```
R <- współczynnik.determinacji(Y, Y.hat)
```

Jego wartość wynosi 0.999386, co świadczy o bardzo dobrym dopasowaniu modelu.

Wartości skorygowanego współczynnika determinacji obliczamy ze wzoru

$$Adj\ R^2 = 1 - \frac{(1 - R^2) \cdot (n - 1)}{n - p - 1}$$

zaimplementowanego w funkcji *skorygowany.współczynnik.determinacji()*.

```
skorygowany.współczynnik.determinacji<-function(R,n,p){  
  return(1 - ((1 - R) * (n - 1)) / (n - p - 1))  
}
```

```
R.adj <- skorygowany.współczynnik.determinacji(R, length(Y), length(beta))
```

Jego wartość wynosi 0.9993501, skorygowany współczynnik determinacji wykazuje mniejszą wartość, niż zwykły współczynnik determinacji, ale nadal wskazuje na bardzo dobre dopasowanie modelu.

5 Zadanie 4

5.1 Podpunkt (a)

Współczynnik podbicia wariancji VIF_j określamy wzorem

$$VIF_j = \frac{1}{1 - R_j^2},$$

gdzie R_j^2 jest współczynnikiem determinacji w modelu regresji liniowej, w którym

- zmienna X_j jest zmienną objaśnianą,
- zmienne $X_0, X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_{p-2}, X_{p-1}$ są zmiennymi objaśniającymi

```
VIF<-function(y,y.est){  
  vif <- 1 / (1 - współczynnik.determinacji(y, y.est))  
  return(vif)  
}
```

5.2 Podpunkt (b)

W danym modelu odrzucamy zmienną X_j o największej wartości VIF_j , jeżeli przekracza ona wartość 10.

Wartości współczynnika VIF_j można obliczyć za pomocą funkcji *VIF()*.

```

testuj<-1:10

while(TRUE){
  Vif.value<-numeric(10)

  for (i in 1:10){
    if (testuj[i]!=0){
      indeksy <- setdiff(which(testuj>0), i)
      b <- estymatory.beta(X[,indeksy], X[,i])
      Y.h <- prognoza(X[,indeksy], b)
      Vif.value[i] <- VIF(X[,i], Y.h)
    }
  }

  if (max(Vif.value) <= 10){
    break
  }

  idx <- which(Vif.value == max(Vif.value))
  testuj[idx] <- 0
}

new.X.1 <- cbind(rep(1, length(X[,1])), X[,which(testuj>0)])
new.X <- X[,which(testuj>0)]

kable(testuj)

```

```

-
x
-
1
2
3
4
5
6
7
0
0
0
-

```

Jak możemy zauważyć w modelu pozostało 7 z 10 zmiennych objaśniających, co znaczy, że istniały istotne współkorelacje. Model dokładnie wyrzucił zmienne o numerach 8, 9 i 10.

6 Zadanie 5

6.1 Podpunkt (a)

Określamy macierz $\mathbb{H}$ następująco:

$$\mathbb{H} := \mathbb{X}(\mathbb{X}^T \mathbb{X})^{-1} \mathbb{X}^T$$

Wówczas wartość $x_j = (x_{1,j}, x_{2,j}, \dots, x_{p-1,j})$ jest wpływowa, gdy

$$h_{j,j} > \frac{3p}{n}.$$


Implementujemy wzór na macierz $\mathbb{H}$.

```
macierz.H <- new.X.1 %*% solve(t(new.X.1) %*% new.X.1) %*% t(new.X.1)
diagonal <- diag(macierz.H)
p <- sum(testuj>0)
u.1 <- which(diagonal > (3 * p / length(diagonal)))
```

Tworzymy wykres zależności wartości wpływów od numeru obserwacji, z naniesionym progiem odcięcia równym $3p/n$.

```
n <- 200
plot(x=1:n, y=diagonal[1:n],
     xlab="indeks",
     ylab="wpływ",
     main="Wartości wpływów dla kolejnych obserwacji")
text(x=u.1, y=diagonal[u.1], labels=u.1, cex=0.7, pos=2)
abline(h = 3*p/n, col="red")
```

Wartości wpływów dla kolejnych obserwacji



Bazując na razie tylko na wykresie wpływów kolejnych obserwacji, możemy stwierdzić, że obserwacje numer 149, 195 są wpływowe.

6.2 Podpunkt (c)

Studentyzowane rezyduum r_i jest zdefiniowane jako

$$r_i = \frac{y_i - \hat{y}_i}{\hat{\sigma} \sqrt{1 - h_{i,i}}},$$

przy czym

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}$$

i ten estymator jest zaimplementowany w funkcji *sigma.est()*.

Wówczas wartość $x_j = (x_{1,j}, x_{2,j}, \dots, x_{p-1,j})$ jest wpływowa, gdy

$$|r_i| > 2.$$

Estymator $\hat{\sigma}^2$ implementujemy w funkcji *sigma.est()*.

```
sigma.est<-function(y,y.hat,beta){  
  return(sum((y-y.hat)^2)/(length(y)-length(beta)))}
```


Wyznaczamy studentyzowane rezydua.

```
new.beta <- estymatory.beta(new.X, Y)  
new.Y.hat <- prognoza(new.X, new.beta)  
new.sigma <- sigma.est(Y, new.Y.hat, new.beta)  
r <- (Y - new.Y.hat) / (new.sigma * sqrt(1 - diagonal))  
u.2 <- which(abs(r) > 2)
```

Tworzymy wykres zależności wartości studentyzowanych rezyduuów od numeru obserwacji, z naniesionymi progami odcięcia równymi 2 oraz -2.

```
n <- 200  
plot(x=1:n, y=r[1:n],  
      xlab="indeks",  
      ylab="wpływ",  
      main="Wartości studentyzowanych rezyduów dla kolejnych obserwacji")  
text(x=u.2, y=r[u.2], labels=u.2, cex=0.7, pos=2)  
abline(h = 2, col="red")  
abline(h = -2, col="red")
```

Wartości studentyzowanych rezyduów dla kolejnych obserwacji



Na wykresie studentyzowanych rezyduów dla kolejnych obserwacji, obserwacje, które są wpływowe według tego testu to 5, 31, 41, 43, 51, 53, 104, 143, 154, 167

6.3 Podpunkt (b)

Określamy odległość Cooka D_i następująco:

$$D_i = r_i^2 \cdot \frac{h_{i,i}}{1 - h_{i,i}} \cdot \frac{1}{p},$$

Wówczas wartość $x_j = (x_{1,j}, x_{2,j}, \dots, x_{p-1,j})$ jest wpływowa, gdy

$$D_i \geq \frac{4}{n - p}.$$

Wyznamy odległości Cooke'a dla kolejnych obserwacji.


```
D <- r^2 * (diagonal / (1 - diagonal)) * (1 / p)
n <- length(Y)
u.3 <- which(D >= (4 / (n - p)))
```

Tworzymy wykres zależności wartości odległości Cooke'a od numeru obserwacji, z naniesionym progiem odcięcia równym $4/(n - p)$.

```
n <- 200
plot(x=1:n, y=D[1:n],
     xlab="indeks",
     ylab="wpływ",
     main="Wartości odległości Cooke'a dla kolejnych obserwacji")
```

```
text(x=u.3, y=D[u.3], labels=u.3, cex=0.7, pos=2)
abline(h = 4 / (n-p), col="red")
```

Wartosci odleglosci Cooke'a dla kolejnych obserwacji



Z wykresu wartości odległości Cooke'a możemy odczytać, że według tego testu obserwacje wpływowe to 5, 17, 31, 41, 43, 51, 71, 96, 104, 129, 147, 154, 167, 195

7 Zadanie 6

7.1 Podpunkt (a)

```
usuniete <- unique(c(u.1, u.2, u.3))
new.X.2 <- new.X[-usuniete, ]
new.Y.2 <- Y[-usuniete, ]
new.beta.2 <- estymatory.beta(new.X.2, new.Y.2)

kable(new.beta.2)
```

wektor.1	0.0810122
X1	2.0145877
X2	4.0044840
X3	6.2000179
X4	3.9922212
X5	0.0497413
X6	5.9783250
X7	1.0506423

7.2 Podpunkt (b)

```
new.Y.hat.2 <- prognoza(new.X.2, new.beta.2)
p.value.nowe <- test.F(new.X.2, new.Y.2, new.Y.hat.2)
```

Tak, przynajmniej jedna ze zmiennych objaśniających ma liniowy wpływ na zmienną objaśnianą, ponieważ wartość p-value wynosi 0, co sugeruje, że powinniśmy odrzucić H_0 o niewpływowości zmiennych objaśniających.

7.3 Podpunkt (c)

```
R.nowe <- współczynnik.determinacji(new.Y.2, new.Y.hat.2)
R.adj.nowe <- skorygowany.współczynnik.determinacji(
  R.nowe,
  length(new.Y.2),
  length(new.beta.2)
)
```

Wartość współczynnika determinacji i wersji skorygowanej odpowiednio wynoszą 0.9995028 i 0.9994799, co wskazują na prawie idealne dopasowanie. Usunięcie niektórych zmiennych i obserwacji nie znacznie polepszyło dopasowanie modelu. Czyli ten model regresji ma sens.