

Raport z listy 6

Modele regresji i ich zastosowania

Ksawery Józefowski, album 277513

2026-04-15

Spis treści

1	Wstęp	1
2	Zadanie 1	2
2.1	Podpunkt (a)	2
2.2	Podpunkt (b)	2
2.3	Podpunkt (c)	4
2.4	Podpunkt (d)	5
2.5	Podpunkt (e)	6
3	Zadanie 2	7
3.1	Podpunkt (a)	7
3.2	Podpunkt (b)	7
3.3	Podpunkt (c)	8

1 Wstęp

Wczytujemy dane z pliku *regresja wielokrotna 2026.xlsx*.

```
library(kableExtra)
dane <- read.csv("C:/Users/ksawe/Desktop/MREG/lab6.csv")

X <- as.matrix(dane[, -8])
Y <- as.matrix(dane[, 8])
```

2 Zadanie 1

2.1 Podpunkt (a)

Wykorzystamy funkcję `step()`. Na początek utworzymy model początkowy (tylko ze stałą) oraz model pełny (ze wszystkimi predyktorami).

```
model.initial <- lm(Y ~ 1, data = dane)
```

```
model.full <- lm(Y ~ ., data = dane)
```

Zacznijmy od modelu regresji krokowej typu “forward”.

```
model.forward <- step(model.initial,
                      scope = list(lower = model.initial, upper = model.full),
                      direction = "forward")
```

Wniosek: Regresja krokowa typu forward stopniowo włączała do modelu zmienne w następującej kolejności: $X_6, X_2, X_4, X_3, X_7, X_1$. Zmienna objaśniająca X_5 nie została uwzględniona w modelu, co wskazuje na jej brak istotnego wpływu na zmienną objaśnianą.

Następnie sprawdzimy model regresji krokowej typu “backward”.

```
model.backward <- step(model.full,
                      direction = "backward")
```

Wniosek: Regresja krokowa typu backward rozpoczęła się od pełnego modelu zawierającego wszystkie zmienne, a następnie usunęła zmienną X_5 . Ostatecznie w modelu pozostały zmienne $X_1, X_2, X_3, X_4, X_6, X_7$, co potwierdza, że (X_5) nie miała istotnego wpływu.

Na koniec zobaczmy jeszcze jak wygląda model regresji krokowej typu “both”.

```
model.both <- step(model.initial,
                  scope = list(lower = model.initial, upper = model.full),
                  direction = "both")
```

Tutaj również usunięty został predyktor X_5 .

Zatem do dalszej analizy wykorzystujemy model backward i oznaczamy go M , dodatkowo z modelu wyłączamy zmienną objaśniającą X_5

```
M <- model.backward
X.M <- X[, -5]
```

2.2 Podpunkt (b)

Do zweryfikowania hipotezy zerowej

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_{p-2} = \beta_{p-1} = 0,$$

przy alternatywie

$$H_1 : \beta_1 \neq 0 \quad \vee \quad \beta_2 \neq 0 \quad \vee \quad \dots \quad \vee \quad \beta_{p-2} \neq 0 \quad \vee \quad \beta_{p-1} \neq 0,$$

wykorzystamy statystykę testową F określoną następująco:

$$F : = \frac{SSR}{SSE} \cdot \frac{n-p}{p-1},$$

gdzie

- n jest długością próby,
- p jest liczbą zmiennych objaśniających powiększoną o jeden (zmienną $X_0 = 1$),
- $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$,
- $SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$

Hipotezę H_0 odrzucamy, gdy p-wartość określona jako

$$p - value = \mathbb{P}_{H_0}(F \geq F_{obs}) = 1 - F_{p-1, n-p}(F_{obs})$$

spełnia

$$p - value \leq \alpha$$

dla ustalonego wcześniej poziomu istotności α , przy czym $F_{m_1, m_2}(t)$ jest dystrybuantą rozkładu F Snedecora, z m_1, m_2 stopniami swobody, ewaluowaną w punkcie t .

Opisany test został zaimplementowany w funkcji $test.F()$.

```
test.F<-function(x,y,y.hat){  
  
  # liczba zmiennych plus 1 (wyraz wolny w modelu regresji)  
  p<-length(x[1,])+1  
  
  # liczba obserwacji  
  n<-length(x[,1])  
  
  # SSR oraz SSE zgodnie ze wzorami  
  SSR<-sum((y.hat-mean(y))^2)  
  SSE<-sum((y-y.hat)^2)  
  
  # wartość statystyki testowej  
  F.stat<-SSR/(p-1)/SSE*(n-p)  
  
  # p-wartość testu  
  p.value<-pf(F.stat,df1=p-1,df2=n-p,lower.tail=FALSE)  
  return(p.value)}
```

```
Y.hat <- M$fitted.values
p.value <- test.F(X.M, Y, Y.hat)
```

Skoro $p\text{-value } 2.0047721 \times 10^{-291}$ jest mniejsze niż zakładany poziom istotności $\alpha = 0.05$ to odrzucamy hipotezę zerową, czyli chociaż jedna zmienna objaśniająca ma istotny liniowy wpływ na zmienną objaśnianą, więc model ma sens.

2.3 Podpunkt (c)

Do zweryfikowania hipotezy zerowej

$$H_0^{(i)} : \beta_i = 0,$$

przy alternatywie

$$H_1^{(i)} : \beta_i \neq 0,$$

wykorzystamy statystykę testową F_i określoną następująco:

$$F_i = \frac{\hat{\beta}_i^2}{SE_i^2},$$

gdzie $SE_i^2 = \hat{\sigma}^2(X^T X)^{-1}_{i,i}$.

Przy założeniu, że $H_0^{(i)}$ jest prawdziwa F_i ma rozkład F Snedecora $F(1, n - p)$ z jednym i $n - p$ stopniami swobody.

Co więcej, statystyka ta ma również rozkład taki sam rozkład jak $[T(n - p)]^2$, czyli kwadrat zmiennej losowej T-studenta z $n - p$ stopniami swobody.

Hipotezę $H_0^{(i)}$ odrzucimy, gdy

$$p\text{-value} = 1 - F_{F(1, n-p)}(F_{i, obs})]$$

spełnia $p\text{-value} \leq \alpha$, gdzie α to ustalony poziom istotności, natomiast $F_{F(m_1, m_2)}(t)$ jest dystrybuantą rozkładu F Snedecora z m_1, m_2 stopniami swobody ewaluowaną w punkcie t .

Ten test został zaimplementowany w funkcji `test.F.single()`.

```
sigma.est<-function(y,y.hat,beta){
  return(sum((y-y.hat)^2)/(length(y)-length(beta)))}
```

```
test.F.single<-function(x,y,y.est,beta){
  sigma <- sigma.est(y,y.est,beta)
  x <- cbind(rep(1,length(x)),x)
  SE <- sigma * diag(solve(t(x)%*%x))

  F.stat <- (beta^2)/SE
```

```

p.value.single <- pf(F.stat, df1=1, df2=length(x)-length(beta),
                     lower.tail=FALSE)

return(p.value.single)
}

```

```

p.value.single <- test.F.single(X.M, Y, Y.hat, M$coefficients)
kable(p.value.single)

```

	x
(Intercept)	0.3835201
X1	0.0000000
X2	0.0000000
X3	0.0000000
X4	0.0000000
X6	0.0000000
X7	0.0000000

Zatem każda ze zmiennych objaśniających ma liniowy wpływ na zmienną objaśnianą, ponieważ każde p-value jest poniżej ustalonego poziomu istotności, więc dla każdego odrzucamy hipotezę H_0

2.4 Podpunkt (d)

Przedział ufności $[T_L(X), T_U(x)]$ na poziomie ufności $1 - \alpha$ dla parametrów β_i , przy założeniu, że $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ są i.i.d o rozkładzie $\mathcal{N}(0, \sigma^2)$ wyznaczamy ze wzorów

$$T_L(X) = \hat{\beta}_i - t_{n-p}(1 - \alpha/2) \cdot SE_i, \quad T_U(X) = \hat{\beta}_i + t_{n-p}(1 - \alpha/2) \cdot SE_i,$$

gdzie $t_{n-p}(1 - \alpha/2)$ jest kwantylem rzędu $1 - \alpha/2$ rozkładu $T(n - p)$ t-Studenta z $n - p$ stopniami swobody.

```

przedziały.ufności<-function(x,y,y.est,beta,alpha){
  sigma <- sigma.est(y,y.est,beta)
  x <- cbind(rep(1,length(x)),x)
  SE <- sigma * diag(solve(t(x)%*%x))

  t.value <- qt(1-alpha/2, df=length(x)-length(beta))

  t.lower <- beta - t.value * sqrt(SE)
  t.upper <- beta + t.value * sqrt(SE)

  przedziały <- cbind(t.lower, beta, t.upper)
}

```

```
return(przedziały)
}
```

```
przedziały <- przedziały.ufności(X.M, Y, Y.hat,
                                M$coefficients, 0.05)
kable(przedziały)
```

	t.lower	beta	t.upper
(Intercept)	-0.7882109	-0.2424902	0.3032305
X1	1.9078108	2.0256639	2.1435171
X2	3.9784374	4.0033689	4.0283004
X3	6.1025992	6.2205392	6.3384793
X4	3.9376053	4.0047997	4.0719942
X6	5.9593729	5.9857816	6.0121903
X7	0.9987043	1.0449285	1.0911527

Wnioski: Żaden z przedziałów ufności nie obejmuje zera, co oznacza, że wszystkie zmienne objaśniające są statystycznie istotne.

2.5 Podpunkt (e)

```
# funkcja jak na liście 4
współczynnik.determinacji<-function(y,y.est){
  return(sum((y.est-mean(y))^2)/sum((y-mean(y))^2))
}

# funkcja jak na liście 4
skorygowany.współczynnik.determinacji<-function(R2,n,p){
  return(1-((1-R2)*(n-1))/(n-p-1))
}
```

```
R2 <- współczynnik.determinacji(Y, Y.hat)


Adj.R2 <- skorygowany.współczynnik.determinacji(
  R2,
  length(Y),
  length(M$coefficients)
)
```

Wnioski: Współczynnik determinacji 0.9995067 oraz skorygowany współczynnik 0.9994871 wskazują na bardzo dobre dopasowanie modelu do danych. Niewielka różnica między tymi wartościami sugeruje, że model nie jest przeparametryzowany, a uwzględnione zmienne objaśniające w istotny sposób wyjaśniają zmienność zmiennej zależnej. Model dobrze dopasowuje się do danych.

3 Zadanie 2

3.1 Podpunkt (a)

```
e <- Y - Y.hat
```



Rysunek 1: Wykres kwantylowy rezyduów

Wnioski: Wykres kwantylowy 1 wygląda dobrze i wskazuje na to, że reszty zachowują się jak reszty dla rozkładu normalnego


3.2 Podpunkt (b)

Wykres rozrzutu rezyduów względem każdej ze zmiennych objaśniających X_i dla $i = 1, 2, 3, 4, 6, 7$ jest przedstawiony na rysunku 2.

```
par(mfrow=c(2,3), mar=c(6,4,2,1))

idx <- c(1,2,3,4,6,7)

for(i in 1:ncol(X.M)){
  plot(X.M[, i], e,
       xlab = colnames(X.M)[i],
       ylab = "Reszty",
       main = paste("Reszty ", colnames(X.M)[i]))
  abline(h = 0, col = "red")
}
```




Rysunek 2: Wykres rozrzutu rezyduów względem wartości zmiennej x

```
par(mfrow=c(1,1))
```

Z wykresu 2 zauważamy, że reszty w porównaniu do każdej zmiennej objaśniającej zachowują się losowo. Oznacza to, że model jest liniowy, a reszty nie są skorelowane ze zmiennymi.

3.3 Podpunkt (c)

Wykres rozrzutu rezyduów względem estymowanych wartości jest przedstawiony na rysunku 3.



Rysunek 3: Wykres rozrzutu rezyduów względem prognoz

Wykres 3 pokazuje losową chmurę punktów co wskazuje, że reszty i wartości predykowane nie są skorelowane.